

Guide de Rapport – Projet IA Générative (Format recommandé et Attentes)

Structure recommandée

1. Page de garde

A Inclure : Logo de l'Efrei, titre du projet, noms binôme + promotion / Mastère Data Engineering et IA + Année universitaire, nom du tuteur / tutrice, Date du rapport, mention obligatoire : Projet certifiant RNCP40875 Expert en Ingénierie de Données – Bloc 2 : Pilotage et implémentation de solutions IA

2. Résumé Exécutif (1 page)

Court résumé incluant : but du projet, principaux choix techniques, résultats obtenus, outil développé, technologies majeures (SBERT, Similarité, RAG, API GenAI, Streamlit, etc.). Ce résumé doit permettre de comprendre le projet sans lire le rapport en entier.

3. Introduction et Contexte

Expliquer la problématique adressée (orientation métier, films, vins, parfums, etc.), le contexte industriel, le cadre théorique, pourquoi utiliser : Analyse sémantique, Embeddings SBERT, RAG, IA Générative (indiquer que l'usage est limité pour éviter d'utiliser des ressources payantes ; objectifs pédagogiques).

4. Analyse du besoin utilisateur

Vous devez démontrer que vous connaissez votre utilisateur : type d'utilisateur visé, objectifs utilisateurs, scénarios d'usage, hypothèses et contraintes...

5. Méthodologie de travail et gestion de projet

Décrire la méthodologie adoptée (Agile / Kanban / Hybrid), le découpage en tâches, le planning (Gantt ou autre), l'organisation du travail en binôme, les outils collaboratifs (GitHub, Trello, ...), et la gestion des risques. Illustrer avec une capture du tableau de suivi ou de visuel Gantt...

6. Référentiel de données

Décrire de manière structurée le référentiel produit, en explicitant : le corpus et sources de données, le modèle conceptuel et le schéma de données définis, le format de restitution final (CSV, JSON, ou intégration SQL), et les modèles de données ou approches de modélisation utilisés.

7. Pipeline IA et Architecture

schéma explicatif, lisible et obligatoire doit présenter la chaîne de traitement de bout en bout. Il doit inclure au minimum :

1. la collecte ou le questionnaire utilisateur,
2. les opérations de pré-traitement,
3. la construction des embeddings SBERT,
4. le calcul de similarité cosinus,

5. les mécanismes d'agrégation et de scoring,
6. la génération des recommandations Top-N,
7. l'usage contrôlé d'un modèle GenAI via un pipeline RAG pour planification, synthèse et justification.

Le schéma peut intégrer toute autre étape complémentaire reflétant votre implémentation réelle. Donc, vous pouvez compléter ce pipeline avec d'autres composants selon les choix techniques réalisés.

8. Implémentation Technique

Décrire en détail :

- Architecture globale de la solution : vue d'ensemble du pipeline (backend, frontend, stockage, API), composants principaux et interactions.
- Technologies utilisées : langages, frameworks, librairies et argumentation des choix (performance, simplicité, maintenabilité, compatibilité pédagogique...).
- Choix du modèle SBERT : à titre d'exemple : variante retenue (ex. all-MiniLM, multi-qa, modèle français, etc.), raisons du choix, mode de chargement et d'utilisation.
- Calcul des similarités : à titre d'exemple : métrique utilisée (cosinus), gestion des matrices de similarité, optimisation éventuelle (batching, filtrage, seuils)...
- Système de score et pondérations : à titre d'exemple : combinaison des similarités avec d'autres critères (contraintes, filtres), pondérations choisies et justification.
- Logique métier du classement : règles de ranking (Top-N), priorisation des résultats pertinents.
- API GenAI : mode d'appel (RAG ou autre), stratégie de limitation des appels (seuils, ...).
- Interface utilisateur (Streamlit ou autre) : structure des pages, flux utilisateur, composants interactifs (formulaire, affichage des recommandations, explications).
- Dépôt Git : organisation du projet (structure des dossiers, modules), gestion des imports, fichiers de configuration (requirements.txt, .env le cas échéant), listing des librairies principales et éventuel usage des branches.
- Gouvernance et responsabilisation : gouvernance prise en compte ou future souhaitable tels que : qualité, maîtrise et traçabilité des données, droits d'accès et nettoyage contrôlés, validation humaine des réponses, choix responsable des modèles (coût, transparence, fiabilité), respect RGPD si produit réel, audit de biais, journalisation des appels GenAI et sécurisation des flux API, gestion de risques sur les aspects éthique, opérationnels, sécurité, et conformité (tels que dépendance API externe, hallucinations si RAG mal construit, limites de modèle non fine-tuné, etc.), monitoring de performance et dérive conceptuelle, correction et mise à jour régulière, etc.

9. Interface utilisateur / Prototype

Captures d'écran : questionnaire, résultats, graphiques (radar, bar chart, etc.), recommandations affichées...

10. Résultats et Tests (Démonstrations)

A titre d'exemple, présenter les démonstrations avec plusieurs profils utilisateurs, tableaux des scores par bloc/catégorie, résultats du moteur de recommandations, exemples de bio ou plan de progression générés, visualisations comparées (radar, heatmap), etc.

11. Limites et pistes d'amélioration

Analyse critique des limites du modèle SBERT utilisé, de la variabilité des similarités, du dataset à taille limité, du coût potentiellement élevé si API non limitée, de l'améliorations possibles (fine-tuning, DB vectorielle, chatbot guidé, etc.)...

12. Conclusion

Synthèse sur ce que vous avez réussi à faire, ce que vous avez appris, quelles compétences du métier cela illustre, etc.

13. Annexes (optionnel)

- Arborescence du projet
- Schémas UML
- Exemple de fichier JSON/CSV
- Prompts utilisés pour GenAI : un appel pour plan, un pour bio
- ...

Consignes de rédaction

- 20–30 pages (hors annexes)
- Police simple (Times New Roman 12, Arial/Calibri 11), interligne 1,
- Style professionnel et structuré
- Illustrer avec captures d'écran, schémas, tableaux

Consignes de Soutenance (Format recommandé et Attentes)

La soutenance doit être **courte, professionnelle et structurée**.

Durée totale : **9 à 10 minutes**, intégrant la session de Q/R.

Conseil : Pendant la présentation, allez directement à l'essentiel et évitez d'entrer trop dans les détails.

Contenu recommandé pour les diapos de soutenance

Les diapos doivent reprendre la structure du rapport, en version synthétique et centrée sur les éléments essentiels.

Elles peuvent être réorganisées selon votre préférence, à condition de conserver un fil conducteur clair, une cohérence logique et un contenu adapté au temps de présentation.

Présentation du projet et Contexte

- Problématique adressée
- Contexte métier et utilisateurs visés
- Objectif du projet
- Pitch en une phrase (ex : “ Un moteur de recommandation IA sémantique basé sur SBERT et assisté par l’IA Générative via RAG pour ...”)

Analyse du besoin utilisateur

- Personne cible
- Scénarios d’usage (1 ou 2 exemples)
- Contraintes et hypothèses

Méthodologie de travail et Organisation

- Approche de gestion de projet (Agile / Kanban / hybride)
- Planification : jalons, Gantt ou mini roadmap...
- Répartition des tâches et collaboration en binôme
- Outils utilisés (GitHub, Trello/Notion, Teams, etc.)
- Gestion des risques et imprévus

Architecture globale et Choix technologiques

- Vue d’ensemble de la solution (backend, frontend, API)
- Rôle de chaque composant
- Justification synthétique des choix techniques

Pipeline IA et Architecture

- Schéma visuel clair du parcours utilisateur de bout en bout (à adapter selon votre réalisation technique) : Collecte ; pré-processing ; embeddings SBERT ; similarité cosinus ; scoring : Top-N ; RAG limité
- Mini-focus sur les étapes critiques (préprocessing, embeddings, scoring)
- Éventuels modules additionnels selon votre implémentation

Référentiel de données

- Sources de données utilisées
- Modélisation de données
- Format retenu (CSV / JSON / SQL)
- Extraits illustratifs

Implémentation Technique (éléments clés)

- Modèle SBERT retenu + raison du choix
- Calcul des similarités (cosinus, filtrage, seuils éventuels)
- Système de scoring et pondérations
- Stratégie RAG et usage API GenAI contrôlé (limitations)
- Structure du dépôt Git et principales librairies (Pas de code sauf snippet court et lisible, si besoin)
- Gouvernance

Démonstration Live

- Questionnaire / Input utilisateur
- Résultats Top-N
- Visualisation (radar / bar chart / tags)
- Justification rapide des scores
- Exemple de génération GenAI (bio, plan, synthèse)
- Attention:
 - Préparer en amont votre démo et les entrées pour éviter de perdre du temps)
 - Prévoir au moins 1 cas alternatif si le temps le permet
 - Avoir screenshots en backup si API lente ou courte démo enregistrée

Résultats et Tests

- Comparaison de profils utilisateurs
- Scores ou regroupements significatifs

- Comportement observé du modèle
- Vérification du bon fonctionnement

Limites et pistes d'amélioration

- Limites du dataset ou SBERT
- Qualité variable des embeddings
- Latence et coût API potentiels
- Améliorations envisagées (fine-tuning, vector DB, chatbot)

Conclusion

- Ce que vous avez réalisé
- Ce que vous avez appris
- Valeur démontrée pour le Mastère. Compétences visées et acquises en pipeline NLP + GenAI + interface + management de projet, ...